

Einfache lineare Regression

Methoden-Dossier mit fachspezifischen Beispielen

1. Methodenbeschreibung

Stell dir vor: Du willst wissen, ob die Außentemperatur beeinflusst, wie viele Leute ins Freibad gehen.

Je wärmer, desto mehr Besucher – das klingt logisch, oder?

Aber wie stark ist dieser Zusammenhang genau? Kann man die Besucherzahl aus der Temperatur vorhersagen?

Genau das macht die einfache lineare Regression: Sie modelliert, wie eine Variable Y (die abhängige, z. B. Besucherzahl) von einer anderen Variable X (der unabhängigen, z. B. Temperatur) abhängt.

Modell: $Y = b_0 + b_1 \cdot X + e$

b_0 ist der Achsenabschnitt – der Wert von Y, wenn $X = 0$ ist (bei 0°C also).

b_1 ist die Steigung – um wie viel Y steigt, wenn X um 1 zunimmt.

e ist der Fehlerterm (Residuum) – der Rest, den das Modell nicht erklären kann.

Geschätzt wird mit der Kleinste-Quadrate-Methode (OLS). Die Prüfung, ob der Einfluss wirklich da ist, macht ein t-Test für $b_1 \neq 0$. Und R^2 sagt dir: Wie viel Prozent der Unterschiede in Y kann X erklären?

Kurz: Regression = 'Hängt Y von X ab, und wenn ja, wie stark?' – eine der wichtigsten Fragen in der Wissenschaft. Und die Antwort steht hier.

2. Fachbereichsspezifische Beispiele

Sozialwissenschaften

Fragestellung: Hängt die Lebenszufriedenheit (0-10) von der wöch. Sportdauer (h) ab? Hypothese: $b_1 > 0$. Datenquelle: SOEP.

Wirtschaftswissenschaften

Fragestellung: Umsatz (T EUR) vorhersagen durch Werbeausgaben (T EUR)? Hypothese: $b_1 > 0$. Anwendung: Marketing-Controlling.

Humanwissenschaften

Fragestellung: Sagt die Anzahl der Wiederholungen die Gedächtnisleistung vorher? Hypothese: $b_1 > 0$. Datengrundlage: Lernexperimente.

Geisteswissenschaften

Fragestellung: Bekanntheitsgrad eines Ereignisses (Index) durch Nennungen in Lehrbüchern? Digital Humanities.

3. Annahmen und Voraussetzungen

- Linearität: Zusammenhang X-Y ist linear (Streudiagramm).
- Normalverteilung der Residuen (Q-Q-Plot).
- Homoskedastizität: konstante Varianz der Residuen (Residuen-Plot).
- Unabhängigkeit der Beobachtungen.

4. Interpretation und Berichterstattung

Signifikanz: $p < 0.05$ -> X hat signifikanten Einfluss auf Y.

R^2 : Anteil erklärter Varianz. Faustregel: > 0.25 guter Fit (Sozialwiss.).

b_1 : Steigt X um 1, steigt Y um b_1 Einheiten.

Bericht: $b = 2.3$, $t(98) = 4.56$, $p < 0.001$, $R^2 = 0.31$

5. Code-Beispiele

R:

```
mod <- lm(y ~ x, data = d)
summary(mod)
confint(mod)
plot(mod) # Diagnostik
```

Python:

```
import statsmodels.api as sm
X = sm.add_constant(d['x'])
mod = sm.OLS(d['y'], X).fit()
print(mod.summary())
```

SPSS:

```
REGRESSION /STATISTICS COEFF R ANOVA CI
/DEPENDENT y /METHOD=ENTER x.
```