

Kreuztabellen & Kontingenzanalyse

Methoden-Dossier mit fachspezifischen Beispielen | Einstiegsniveau

1. Methodenbeschreibung

Stell dir vor: Du hast 200 Personen befragt — nach Geschlecht (m/w/d) und ob sie regelmäßig Sport treiben (ja/nein). Die Rohdaten sind eine lange Liste von Einzelantworten. Um einen Überblick zu bekommen, musst du die Daten in eine Tabelle sortieren. Genau das ist eine Kreuztabelle (Kontingenztafel): Sie zählt aus, wie viele Personen jede Kombination von Ausprägungen zweier kategorialer Variablen aufweisen.

Kreuztabellen sind der erste Schritt jeder kategorialen Datenanalyse. Sie zeigen auf einen Blick, ob ein Zusammenhang zwischen zwei Merkmalen bestehen könnte — noch bevor du einen Chi-Quadrat-Test rechnest.

Aufbau einer Kreuztabelle

Eine Kreuztabelle hat:

- Zeilen: Ausprägungen der ersten Variable (z. B. Geschlecht)
- Spalten: Ausprägungen der zweiten Variable (z. B. Sport)
- Zellen: Anzahl der Fälle pro Kombination (absolute Häufigkeit)
- Randsummen: Zeilen- und Spaltensummen
- Gesamtsumme: N (alle Fälle)

Beispiel 1: Kreuztabelle Geschlecht × Sport (absolute Häufigkeiten)

	Sport: Ja	Sport: Nein	Gesamt
Männlich	60	40	100
Weiblich	75	25	100
Divers	10	10	20
Gesamt	145	75	220

Spaltenprozentage, Zeilenprozentage, Gesamtprozentage

Der entscheidende Punkt: Welche Prozentuierung du nutzt, hängt von deiner Fragestellung ab.

ZEILENPROZENTE (): Jede Zeile summiert sich auf 100%. Du vergleichst die Verteilung der Spaltenvariable INNERHALB jeder Zeile. Sinnvoll, wenn die Zeilenvariable die unabhängige Variable (UV) ist.

Frage: 'Unterscheidet sich der Sportanteil zwischen den Geschlechtern?' Zeilenprozentage: Bei Männern 60 % Sport, bei Frauen 75 % Sport, bei Diversen 50 % Sport.

Beispiel 2: Zeilenprozentage — Vergleich zwischen Gruppen (UV = Geschlecht)

	Sport: Ja	Sport: Nein	Gesamt
Männlich	60 %	40 %	100 %
Weiblich	75 %	25 %	100 %
Divers	50 %	50 %	100 %

SPALTENPROZENTE (↓): Jede Spalte summiert sich auf 100%. Du vergleichst die Verteilung der Zeilenvariable INNERHALB jeder Spalte. Sinnvoll, wenn die Spaltenvariable die UV ist.

Frage: 'Wie verteilt sich das Geschlecht unter Sporttreibenden vs. Nicht-Sporttreibenden?'

Beispiel 3: Spaltenprozentage — Vergleich zwischen Spalten (UV = Sport)

	Sport: Ja	Sport: Nein
Männlich	41,4 %	53,3 %
Weiblich	51,7 %	33,3 %
Divers	6,9 %	13,3 %
Gesamt	100 %	100 %

GESAMTPROZENTE: Jede Zelle wird durch die Gesamtzahl N geteilt. Du siehst, welche Kombination insgesamt am häufigsten ist. Sinnvoll für rein deskriptive Überblicke ohne Kausalrichtung.

Frage: 'Welche Gruppe ist insgesamt am stärksten vertreten?' 34,1 % = weiblich + Sport.

Beispiel 4: Gesamtprozentage — alle Zellen relativ zu N

	Sport: Ja	Sport: Nein	Gesamt
Männlich	27,3 %	18,2 %	45,5 %
Weiblich	34,1 %	11,4 %	45,5 %
Divers	4,5 %	4,5 %	9,0 %
Gesamt	65,9 %	34,1 %	100 %

Faustregel: Wann welche Prozentuierung?

- UV in Zeilen, AV in Spalten Zeilenprozentage (Vergleich der AV-Ausprägungen zwischen Gruppen)
- UV in Spalten, AV in Zeilen Spaltenprozentage
- Explorative Übersicht ohne Kausalrichtung Gesamtprozentage
- Nur absolute Häufigkeiten berichten unzureichend bei unterschiedlichen Gruppengrößen

2. Fachbereichsspezifische Beispiele

Sozialwissenschaften

Fragestellung: Hängt der Bildungsabschluss (Haupt-/Real-/Abitur/Uni) mit dem Wahlverhalten (Partei A/B/C) zusammen?
Hypothese: Bildung beeinflusst Wahlpräferenz. Datenquelle: ALLBUS / SOEP. Methode: Kreuztabelle mit Zeilenprozenten + Chi-Quadrat-Test.

Wirtschaftswissenschaften

Fragestellung: Besteht ein Zusammenhang zwischen Unternehmensgröße (KMU/Groß) und Digitalisierungsgrad (niedrig/mittel/hoch)? Datengrundlage: IW-Zahlen. Interpretation: Zeilenprocente zeigen: Großunternehmen häufiger 'hoch' digitalisiert.

Humanwissenschaften (Medizin / Pflege / Psychologie)

Fragestellung: Rauchen (ja/nein) × Lungenkrebs-Diagnose (ja/nein). Studie mit $n = 500$. 2×2-Tabelle. Zeilenprocente: Raucher haben höheren Krebsanteil. Erweiterung: Berechnung des relativen Risikos (RR) und der Odds-Ratio.

Geisteswissenschaften

Fragestellung: Korpuslinguistik — Verwendung von 'der/die/das' in Texten des 18. vs. 20. Jh. (männlich/weiblich/sächlich je Epoche). Kreuztabelle: Epoche × Artikel. Zeilenprocente zeigen den Wandel des Artikelgebrauchs.

Sportwissenschaften

Fragestellung: Trainingsmethode (A/B/C) × Verletzungsstatus (verletzt/nicht verletzt). $n = 90$ (30 pro Methode). Kreuztabelle + Spaltenprocente: Welche Methode hat den geringsten Verletzungsanteil?

3. Annahmen und Voraussetzungen

- Beide Variablen müssen kategorial sein (nominal- oder ordinalskaliert)
- Unabhängigkeit der Beobachtungen (jede Person nur einmal zählen)
- Erwartete Zellohäufigkeiten ≥ 5 für Chi-Quadrat (sonst: Fisher-Exakt-Test)
- Keine leeren Kategorien (nicht beobachtete Ausprägungen entfernen)
- Prozentuierung immer mit Nennung der Basis (z. B. 'Zeilen-%', $n = 100$)

4. Interpretation und Berichterstattung

Eine Kreuztabelle wird immer wie folgt berichtet:

- Tabelle mit absoluten Häufigkeiten + Prozentuierung (Art angeben)
- Randsummen und Gesamt-N nennen
- Muster beschreiben: 'In der Gruppe X ist der Anteil von Y mit Z % höher/niedriger als in Gruppe W'
- Ergebnis des Chi-Quadrat-Tests anhängen, wenn der Zusammenhang formal geprüft wird

Berichtsbeispiel:

'Tabelle 1 zeigt die Kreuztabelle von Geschlecht und regelmäßigem Sport ($n = 220$). Der Anteil der Sporttreibenden liegt bei Frauen mit 75 % höher als bei Männern (60 %) und Diversen (50 %). Ein Chi-Quadrat-Test bestätigt den signifikanten Zusammenhang ($\chi^2(2) = 8,24$, $p = 0,016$, Cramér's $V = 0,19$).'

5. Code-Beispiele

R — Kreuztabelle + Prozentuierung:

```
# Kreuztabelle erstellen
tab <- table(d$geschlecht, d$sport)
tab

# Zeilenprozentage
prop.table(tab, margin = 1) * 100 # Zeilen = 1

# Spaltenprozentage
prop.table(tab, margin = 2) * 100 # Spalten = 2

# Gesamtprozentage
prop.table(tab) * 100

# Mit dem vcd-Paket (schönere Ausgabe)
library(vcd)
addmargins(tab) # mit Randsummen

# Chi-Quadrat-Test
chisq.test(tab)
```

Python (Pandas + SciPy) — Kreuztabelle + Prozentuierung:

```
import pandas as pd
from scipy.stats import chi2_contingency

# Kreuztabelle erstellen
tab = pd.crosstab(d['geschlecht'], d['sport'])
print(tab)

# Zeilenprozentage
print(tab.div(tab.sum(axis=1), axis=0) * 100)

# Spaltenprozentage
print(tab.div(tab.sum(axis=0), axis=1) * 100)

# Gesamtprozentage
print(tab / tab.values.sum() * 100)

# Chi-Quadrat-Test
chi2, p, dof, expected = chi2_contingency(tab)
print(f' $\chi^2$  = {chi2:.2f}, p = {p:.4f}')
```

SPSS — Kreuztabelle + Prozentuierung:

```
* Kreuztabelle mit Zeilenprozenten  
CROSSTABS  
/TABLES=geschlecht BY sport  
/FORMAT=AVALUE TABLES  
/CELLS=COUNT ROW COLUMN TOTAL  
/STATISTICS=CHISQ PHI.
```

```
* Ausgabe:  
* COUNT = absolute Häufigkeiten  
* ROW = Zeilenprozente  
* COLUMN = Spaltenprozente  
* TOTAL = Gesamtprozente  
* CHISQ = Chi-Quadrat-Test  
* PHI = Cramér's V / Phi
```

6. Erweiterung: Das Simpson-Paradoxon

Ein zentrales Problem bei Kreuztabellen: Der scheinbare Zusammenhang zwischen zwei Variablen kann sich umkehren, wenn eine dritte Variable (Störfaktor) einbezogen wird. Das ist das Simpson-Paradoxon.

Klassisches Beispiel: Geschlechterunterschied bei Uni-Zulassungen (Berkeley). Insgesamt werden Männer häufiger zugelassen als Frauen. Betrachtet man aber die einzelnen Fachbereiche, ist das Verhältnis ausgeglichen. Grund: Frauen bewarben sich häufiger in Fächern mit niedrigerer Zulassungsquote.

Lektion: Eine einzelne 2x2-Kreuztabelle kann täuschen. Bei Verdacht auf Drittvariablen-Einfluss: geschichtete Tabellen (Mantel-Hänszel-Test) oder logistische Regression rechnen.

7. Übungsaufgaben

Aufgabe 1: Ein Sportverein erhebt bei 150 Mitgliedern Trainingsform (Ausdauer/Kraft/Kombiniert) und Verletzung (ja/nein). Erstelle eine Kreuztabelle und berechne Zeilenprozente. In welcher Trainingsform ist der Verletzungsanteil am niedrigsten?

Aufgabe 2: Eine Umfrage (n = 400) untersucht den Zusammenhang zwischen Studienfach (MINT/Sprache/Sozial) und Auslandssemester (ja/nein). Berechne Spaltenprozente. Sind die Unterschiede signifikant?

Aufgabe 3 (Simpson-Paradoxon): In zwei Kliniken (A und B) werden je 100 Patienten mit alter vs. neuer Methode behandelt. In beiden Kliniken ist die neue Methode überlegen, aber zusammengerechnet schneidet die alte Methode besser ab. Warum? Überlege: Wie unterscheiden sich die Kliniken in der Fallzusammensetzung?