

Klassische Testtheorie & Reliabilitätsanalyse

Methoden-Dossier | Basic-Niveau

1. Methodenbeschreibung

Die Klassische Testtheorie (KTT) ist das fundamentale Messmodell der psychologischen und pädagogischen Diagnostik. Sie zerlegt jeden beobachteten Messwert X in einen wahren Wert T und einen Messfehler E : $X = T + E$. Zentrale Annahme: Der Erwartungswert des Messfehlers ist null ($E[E]=0$), und Fehler sind unabhängig vom wahren Wert und untereinander.

Reliabilität (Zuverlässigkeit) ist der Anteil der wahren Varianz an der beobachteten Varianz: $r = \text{Var}(T) / \text{Var}(X)$. Sie gibt an, wie genau/zuverlässig ein Messinstrument misst. Drei Hauptmethoden zur Schätzung:

Interne Konsistenz (Cronbachs Alpha)

Basiert auf den mittleren Korrelationen aller Items eines Tests. $\alpha = (k/(k-1)) * (1 - \sum(\text{Var}_i)/\text{Var}_{\text{ges}})$. Werte 0-1, Faustregel: $\alpha > 0,7$ akzeptabel, $> 0,8$ gut, $> 0,9$ exzellent. Wichtig: Alpha steigt mit der Item Anzahl — ein hohes Alpha allein bedeutet nicht automatisch hohe Qualität.

Test-Retest-Reliabilität

Korrelation zwischen zwei Messungen desselben Tests zu zwei Zeitpunkten. Misst die zeitliche Stabilität. Probleme: Übungseffekte, Erinnerungseffekte, echte Veränderung. Ideal: 2-4 Wochen Abstand.

Split-Half-Reliabilität

Teilt den Test in zwei Hälften (z. B. gerade vs. ungerade Items) und korreliert die Hälften. Korrigiert mit Spearman-Brown-Formel: $r_{\text{ges}} = 2 * r_{\text{halb}} / (1 + r_{\text{halb}})$.

Paralleltest-Reliabilität

Korrelation zwischen zwei parallelen Testformen. Selten praktisch umsetzbar, da parallele Formen schwer zu konstruieren sind.

2. Fachbereichsspezifische Beispiele

Psychologie

Entwicklung eines neuen Depressionsfragebogens (20 Items, 5-stufige Likert-Skala). Cronbachs Alpha = 0,92 im Pilottest (n=150). Itemanalyse: Trennschärfen zwischen 0,35 und 0,72. Drei Items mit Trennschärfe < 0,30 werden entfernt — neues Alpha = 0,94.

Medizin

Gesundheitsfragebogen SF-36: Test-Retest-Reliabilität von 0,85 für die körperliche Summenskala bei 2-Wochen-Abstand. Split-Half-Reliabilität der Schmerzska: $r=0,82$, Spearman-Brown-korrigiert: $r=0,90$.

Sozialwissenschaften

Politikverdrossenheitsskala (5 Items): Alpha = 0,68 — grenzwertig. Nach Tiefenanalyse wird ein Item mit negativer Trennschärfe entfernt (Formulierung zu komplex). Verbessertes Alpha = 0,76.

Sportwissenschaften

Fragebogen zur intrinsischen Motivation im Sport (10 Items). Cronbachs Alpha = 0,88. Split-Half: $r=0,79$, Spearman-Brown = 0,88. Test-Retest nach 3 Wochen: $r=0,81$.

Wirtschaftswissenschaften

Mitarbeiterzufriedenheitsumfrage (15 Items). Gesamtskala Alpha = 0,91. Subskalen: Arbeitsbedingungen (5 Items, $\alpha=0,84$), Führung (5 Items, $\alpha=0,88$), Gehalt (5 Items, $\alpha=0,72$).

3. Annahmen und Voraussetzungen

- $X = T + E$ (additives Modell)
- $E[E] = 0$ (kein systematischer Fehler)
- $r(T, E) = 0$ (Fehler unabhängig vom wahren Wert)
- $r(E_i, E_j) = 0$ (Fehler zwischen Items unabhängig)
- Mindestens 2 Items pro Skala (besser 3-5 für stabiles Alpha)
- Metrische oder ordinale Items (Likert-Skala ab 5 Stufen als metrisch akzeptiert)

4. Interpretation und Berichterstattung

Reliabilitätskoeffizient mit 95%-KI angeben (nicht nur Punktwert)

Item Anzahl, Stichprobengröße und Skalierung berichten

Bei Alpha: "Cronbachs Alpha betrug $\alpha = 0,87$ (95 %-KI [0,82; 0,91], n = 200, 10 Items)."

Item Kennwerte (Mittelwert, SD, Trennschärfe, Schwierigkeit) tabellarisch

Alpha-wenn-Item-gelöscht-Tabelle berichten

Bei Test-Retest: Zeitintervall und Stichprobenbeschreibung

5. Code-Beispiele

R - Reliabilitätsanalyse:

```
library(psych)
# Daten: Items als Spalten
alpha(items) # Cronbachs Alpha + Itemstatistiken

# Detailliert mit KI
alpha(items, check.keys=TRUE)

# Split-Half
splitHalf(items)

# Test-Retest (Pearson/spearman Korrelation)
cor.test(t1_score, t2_score, method="pearson")
```

Python - Reliabilität:

```
import pandas as pd
from pingouin import cronbach_alpha
# Daten: Items als Spalten
alpha, ci = cronbach_alpha(data)
print(f"Alpha = {alpha:.3f}, 95% CI [{ci[0]:.3f}, {ci[1]:.3f}]")

# Split-Half manuell (gerade/ungerade)
half1 = data.iloc[:, ::2].sum(axis=1)
half2 = data.iloc[:, 1::2].sum(axis=1)
from scipy.stats import pearsonr
r_half = pearsonr(half1, half2)[0]
r_full = 2 * r_half / (1 + r_half) # Spearman-Brown
```

SPSS:

```
RELIABILITY /VARIABLES=item1 item2 item3 item4 item5 /SCALE(All) ALL /MODEL=ALPHA
/STATISTICS=DESCRIPTIVE SCALE CORR /SUMMARY=TOTAL.
```

6. Erweiterung

Grenzen von Cronbachs Alpha

Alpha setzt essenzielle tau-Äquivalenz voraus (alle Items laden gleich stark auf dem wahren Faktor). Bei verletzter Annahme (z. B. bei faktoriell komplexen Skalen) ist Alpha zu niedrig. Bessere Alternative: McDonalds Omega (ω_{total}) aus der Faktorenanalyse.

McDonalds Omega

Basiert auf der Faktorenladungsmatrix. $\Omega = 1 - (\sum(1-h^2) / \text{Var}_{\text{ges}})$. h^2 = Kommunalität. Ist robuster als Alpha bei verletzter tau-Äquivalenz. In R: `omega(items)` aus dem psych-Paket.

Interrater-Reliabilität

Für Beobachterübereinstimmung: Cohens Kappa (2 Rater, nominal), ICC (Intraklassenkorrelation, metrisch), Fleiss Kappa (>2 Rater). Anwendung: Diagnostische Einschätzungen, Verhaltenscodierung, Inhaltsanalyse.

Itemanalyse-Kennwerte

Item Schwierigkeit: p = Mittelwert / max. Punktzahl (0-1). Ideal: 0,2-0,8.

Trennschärfe: r_{it} = Korrelation Item mit Gesamtscore. Ideal: > 0,3.

Alpha-wenn-Item-gelöscht: Zeigt ob Item die Skala verbessert.

7. Übungsaufgaben

Aufgabe 1: Ein neuer Ängstlichkeitsfragebogen (10 Items, $n=100$) ergibt $\alpha = 0,72$. Die Tabelle "Alpha wenn Item gelöscht" zeigt für Item 4 einen Wert von 0,78. a) Interpretiere. b) Sollte Item 4 entfernt werden? c) Welche Konsequenz hat das für die Inhaltsvalidität?

Aufgabe 2: Test-Retest einer motorischen Leistungsskala ergibt $r=0,95$ bei 1 Tag Abstand, $r=0,68$ bei 4 Wochen Abstand. a) Wie interpretierst du den Unterschied? b) Welcher Wert ist die "wahre" Reliabilität?

Aufgabe 3: Du hast einen 20-Item-Test. Split-Half (gerade/ungerade) ergibt $r=0,70$. a) Berechne die Spearman-Brown-korrigierte Reliabilität. b) Warum ist die Korrektur notwendig?