

PCA & Hauptkomponentenanalyse

Methoden-Dossier mit fachspezifischen Beispielen | Standard-Niveau

1. Methodenbeschreibung

Stell dir vor: Du hast einen Datensatz mit 50 Variablen:

Soziodemographie, Persönlichkeitstests, Gesundheit, Konsumverhalten. Viele dieser Variablen hängen zusammen (z. B. Alter und Gesundheitsbewusstsein).

Wie findest du die zugrunde liegenden Hauptdimensionen? Genau das macht die Hauptkomponentenanalyse (PCA).

PCA ist ein dimensionsreduzierendes Verfahren: Sie fasst viele beobachtete Variablen in wenige künstliche Dimensionen (Hauptkomponenten) zusammen, die möglichst viel der ursprünglichen Varianz erklären. Die erste Hauptkomponente erklärt den größten Varianzanteil, die zweite den zweitgrößten (unkorreliert mit der ersten) usw.

Mathematisch basiert PCA auf der Eigenzerlegung der Korrelationsmatrix (oder Kovarianzmatrix). Die Eigenwerte (λ) geben an, wie viel Varianz jede Komponente erklärt. Die Eigenvektoren sind die Gewichte (Loadings) der ursprünglichen Variablen auf den neuen Komponenten.

Sprich: PCA verwandelt viele korrelierte Variablen in wenige unkorrelierte Komponenten — ideal für Datenvisualisierung, Reduktion von Rauschen und als Vorbereitung für weitere Analysen (Regression, Clusteranalyse).

Die zentralen Konzepte

- Eigenwert > 1 (Kaiser-Kriterium): Komponente erklärt mehr Varianz als eine einzelne Variable
- Scree-Plot: Knick in der Eigenwertkurve zeigt die optimale Anzahl an Komponenten
- Kumulierte Varianz: Faustregel $> 60\text{--}70\%$ für eine gute Repräsentation
- Loadings: Korrelation zwischen ursprünglicher Variable und Komponente (Betrag $> 0,3$ = relevant)
- Rotation (Varimax): Vereinfacht die Interpretation durch höhere/niedrigere Loadings
- Komponentenwerte (Scores): Jede Beobachtung bekommt einen Wert pro Komponente

Beispiel: Eigenwerttabelle einer PCA mit 15 Variablen ($n = 200$). 4 Komponenten nach Kaiser-Kriterium.

Komponente	Eigenwert	Varianz (%)	Kumuliert (%)
PC1	4,82	32,1	32,1
PC2	2,94	19,6	51,7
PC3	1,73	11,5	63,2
PC4	1,21	8,1	71,3
PC5	0,88	5,9	77,2
...	...	...	...

2. Fachbereichsspezifische Beispiele

Sozialwissenschaften

Fragestellung: Reduktion von 20 Items eines Persönlichkeitsfragebogens (Big Five) auf 5 Hauptdimensionen. $n = 1.000$. PCA mit Varimax-Rotation. Interpretation der Komponenten als Extraversion, Neurotizismus, Gewissenhaftigkeit, Offenheit, Verträglichkeit. Datenquelle: SOEP / Online-Panel.

Wirtschaftswissenschaften

Fragestellung: 30 Kennzahlen zur Unternehmensperformance (Umsatz, Gewinn, Liquidität, Verschuldung etc.) auf wenige Faktoren reduzieren. PCA extrahiert 3 Komponenten: 'Rentabilität', 'Stabilität', 'Wachstum'. Kumulierte Varianz: 74 %. Anwendung: Bonitätsrating, Benchmarking.

Humanwissenschaften (Medizin / Psychologie)

Fragestellung: Reduktion von 40 neuropsychologischen Testwerten auf kognitive Hauptdomänen (Gedächtnis, Exekutivfunktionen, Verarbeitungsgeschwindigkeit). $n = 500$ (Patienten + Kontrollen). PCA dient der Datenreduktion vor einer Clusteranalyse zur Identifikation von Patienten-Untergruppen.

Geisteswissenschaften (Digital Humanities)

Fragestellung: Dokument-Term-Matrix eines Textkorpus (500 Texte, 2.000 Wortvektoren). PCA reduziert die Dimensionalität für eine thematische Kartierung. Die ersten beiden Komponenten visualisieren Textähnlichkeiten im 2D-Raum. Anwendung: Stilometrie, Analyse der Autorenschaft.

Sportwissenschaften

Fragestellung: 15 leistungsdiagnostische Tests (Sprungkraft, Sprintzeit, Ausdauer, Beweglichkeit, Koordination) auf wenige Komponenten reduzieren. PCA extrahiert 3 Komponenten: 'Schnellkraft', 'Grundlagenausdauer', 'Koordination'. Ermöglicht eine effiziente Athletenklassifikation ($n = 200$ Athleten).

3. Annahmen und Voraussetzungen

- Metrische Variablen (Intervall-/Ratioskala). Ordinale Variablen können bei 5+ Stufen näherungsweise verwendet werden
- Lineare Zusammenhänge zwischen Variablen. PCA erfasst keine nichtlinearen Strukturen
- Ausreichende Korrelation zwischen Variablen ($KMO > 0,6$; Bartlett-Test $p < 0,05$)
- Keine perfekte Multikollinearität (sonst singuläre Matrix)
- Stichprobengröße: Faustregel $n > 5 \times \text{Anzahl Variablen}$, besser $n > 10 \times p$
- Ausreißer erkennen und behandeln (PCA ist anfällig für extreme Werte)

4. Interpretation und Berichterstattung

Eine PCA wird standardisiert wie folgt berichtet:

- Begründung: Warum PCA? (Dimensionsreduktion, Multikollinearität, Exploration)
- Eignungsprüfung: KMO (MSA) und Bartlett-Test berichten
- Extraktion: Kaiser-Kriterium ($EW > 1$) + Scree-Plot für Entscheidung über Anzahl Komponenten
- Varianztabelle: Eigenwerte, erklärte Varianz (%), kumulierte Varianz (%)
- Rotierte Ladungsmatrix (z. B. Varimax): Loadings $> 0,4$ hervorheben, $< 0,3$ unterdrücken
- Komponenten benennen: Inhaltliche Interpretation der hoch ladenden Variablen
- Optional: Komponentenwerte für weiterführende Analysen speichern

Berichtsbeispiel:

'Eine PCA mit Varimax-Rotation wurde auf 15 Items zur Arbeitszufriedenheit durchgeführt ($n = 340$). Der KMO-Wert betrug 0,82; Bartlett-Test war signifikant ($\chi^2(105) = 1.892$, $p < 0,001$). Nach dem Kaiser-Kriterium wurden 3 Komponenten extrahiert, die zusammen 64,7 % der Gesamtvarianz aufklären. Tabelle 2 zeigt die rotierte Ladungsmatrix. Komponente 1 ('Führung', $EW = 4,2$) umfasst Items zu Vorgesetztenverhalten, Komponente 2 ('Kollegen', $EW = 3,1$) zum Teamklima, Komponente 3 ('Ressourcen', $EW = 2,4$) zu Arbeitsmitteln und Belastung.'

5. Code-Beispiele

R — PCA mit psych-Paket:

```
library(psych)

# PCA extrahieren (5 Komponenten, Varimax)
pca_res <- principal(d, nfactors = 5, rotate = 'varimax', scores = TRUE)

# Ergebnisse anzeigen
print(pca_res$loadings, cutoff = 0.3) # Ladungen
pca_res$values # Eigenwerte
summary(pca_res$Vaccounted) # Varianztabelle

# Scree-Plot
scree(d, factors = FALSE)

# KMO & Bartlett
KMO(d)
cortest.bartlett(cor(d), n = nrow(d))

# Komponentenwerte extrahieren
scores <- pca_res$scores
d$pc1 <- scores[, 1]
```

Python (scikit-learn) — PCA:

```
import pandas as pd
import numpy as np
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

# Standardisieren (zwingend!)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(d)

# PCA durchführen
pca = PCA(n_components=5)
scores = pca.fit_transform(X_scaled)

# Ergebnisse
print('Eigenwerte:', pca.explained_variance_)
print('Varianz (%):', pca.explained_variance_ratio_ * 100)
print('Kumuliert:', np.cumsum(pca.explained_variance_ratio_) * 100)

# Loadings (Eigenvektoren * sqrt(Eigenwert))
loadings = pca.components_.T * np.sqrt(pca.explained_variance_)
loadings_df = pd.DataFrame(loadings, columns=[f'PC{i+1}' for i in range(5)])
print(loadings_df)
```

SPSS — PCA (FACTOR):

```
* PCA mit Varimax-Rotation
FACTOR
/VARIABLES item1 item2 item3 item4 item5
/MISSING LISTWISE
/ANALYSIS item1 item2 item3 item4 item5
/PRINT INITIAL CORRELATION DET KMO EXTRACTION ROTATION
/CRITERIA FACTORS(5) ITERATE(25)
/EXTRACTION PC
/CRITERIA ITERATE(25)
/ROTATION VARIMAX
/SAVE REG(ALL)
/METHOD=CORRELATION.

* Ausgabe: Korrelationsmatrix, KMO/Bartlett, Eigenwerte,
* extrahierte Varianz, rotierte Komponentenmatrix,
* neue Variablen FAC1_1 bis FAC5_1 in Daten.
```

6. Erweiterung: PCA vs. EFA — und wann du was nutzt

PCA und explorative Faktorenanalyse (EFA) werden häufig verwechselt. Der Unterschied:

- PCA: Beobachtete Variablen werden in Komponenten zusammengefasst, die die Gesamtvarianz (inkl. Fehlervarianz) möglichst gut erklären. Ziel: Dimensionsreduktion / Datenkompression.
- EFA: Nur die gemeinsame Varianz wird modelliert, die Fehlervarianz wird separiert. Ziel: Aufdeckung latenter Konstrukte (theoriegetrieben).

Faustregel: Wenn du einfach nur die Dimensionalität reduzieren willst (z. B. für eine nachfolgende Regression), nimm PCA. Wenn du ein theoretisches Konstrukt messen willst (z. B. 'Intelligenz' oder 'Arbeitszufriedenheit'), nimm EFA.

Varimax, Quartimax, Oblimin — welche Rotation?

- Varimax (orthogonal): Komponenten bleiben unkorreliert. Einfachste Interpretation.
- Quartimax: Vereinfacht die Zeilen der Ladungsmatrix. Gut, wenn eine Generalkomponente erwartet wird.
- Oblimin (oblique): Komponenten dürfen korrelieren. Realistischer, aber komplexer.

PCA mit nicht-metrischen Variablen

Für binäre oder ordinale Daten gibt es spezielle Varianten: kategoriale PCA (CATPCA in SPSS) oder Multiple Correspondence Analysis (MCA). Standard-PCA setzt metrische, normalverteilte Variablen voraus.

7. Übungsaufgaben

Aufgabe 1: Ein Datensatz enthält 12 Items zur Studienzufriedenheit ($n = 300$). Der KMO beträgt 0,79. Die ersten 5 Eigenwerte sind: 4,1 / 2,3 / 1,4 / 0,9 / 0,7. Wie viele Komponenten würdest du nach dem Kaiser-Kriterium extrahieren? Wie viel Varianz erklären sie? ($4,1 + 2,3 + 1,4 = 7,8 / 12 = 65\%$)

Aufgabe 2: Führe eine PCA mit dem eingebauten iris-Datensatz in R durch (4 metrische Variablen, $n = 150$). Wie viele Komponenten haben einen EW > 1 ? Welche Variable lädt am stärksten auf PC1? Visualisiere die ersten beiden Komponenten als Scatterplot (farbig nach Species).

Aufgabe 3: Warum müssen die Daten vor einer PCA standardisiert werden? Was passiert, wenn du eine PCA auf der Kovarianzmatrix statt der Korrelationsmatrix rechnest? Zeige am Beispiel von Variablen mit unterschiedlichen Skalen (Größe in cm, Gewicht in kg, Einkommen in €).