

Prüfung: PCA & Hauptkomponentenanalyse

Übungsprüfung mit Lösungen (DE/EN) | Standard-Niveau

HINWEISE

- Trage auf dem Deckblatt deinen Namen und deine Matrikelnummer ein.
- Bearbeitungszeit: 60 Minuten. Gesamtpunktzahl: 32 Pkt. (Aufgaben 1–5 DE, 6–10 EN)
- Erlaubte Hilfsmittel: Formelsammlung, Taschenrechner, Stift.
- Aufgaben 1–5 auf Deutsch, Aufgaben 6–10 auf Englisch.
- Anwendungsaufgaben: Lösungswege dokumentieren. Ergebnisse klar kennzeichnen.
- Die Lösungen befinden sich im Anhang zur Selbstkontrolle.

DEUTSCHER TEIL (Aufgaben 1–5)

1. [Offene Frage] (3 Pkt.) Was ist das Hauptziel einer Hauptkomponentenanalyse (PCA)? Erkläre den Unterschied zwischen PCA und Explorativer Faktorenanalyse (EFA).

2. [Anwendungsaufgabe] (4 Pkt.) Eine PCA mit 20 Variablen ergibt folgende Eigenwerte für die ersten 6 Komponenten:

5,2 | 3,8 | 2,1 | 1,4 | 0,9 | 0,7

- a) Wie viele Komponenten würdest du nach dem Kaiser-Kriterium extrahieren? (1 Pkt.)
- b) Berechne die kumulierte erklärte Varianz für diese Komponenten in Prozent. (2 Pkt.)
- c) Welche zusätzliche Entscheidungshilfe würdest du heranziehen? (1 Pkt.)

3. [Offene Frage] (3 Pkt.) Warum müssen die Daten vor einer PCA standardisiert werden? Was passiert, wenn man eine PCA auf der Kovarianzmatrix statt der Korrelationsmatrix rechnet?

4. [Anwendungsaufgabe] (4 Pkt.) Interpretiere folgende rotierte Ladungsmatrix (Varimax, $n = 250$, 10 Items):

	PC1	PC2	PC3
Item_1	0,82	0,12	0,08
Item_2	0,79	0,05	0,15
Item_3	0,74	-0,08	0,11
Item_4	0,68	0,22	-0,05
Item_5	0,12	0,81	0,03
Item_6	0,08	0,77	0,14
Item_7	-0,05	0,72	0,09
Item_8	0,15	0,11	0,84
Item_9	0,05	0,08	0,79
Item_10	0,18	0,03	0,71

- a) Wie viele Komponenten wurden extrahiert? Benenne sie inhaltlich. (3 Pkt.)
- b) Welches Item lädt auf keiner Komponente hoch ($< 0,4$)? Was würde man tun? (1 Pkt.)

5. [MC] (2 Pkt.) Welche der folgenden Aussagen zur PCA ist richtig? Begründe kurz.

- a) PCA setzt normalverteilte Variablen voraus.
- b) Die Anzahl der Komponenten entspricht der Anzahl der Variablen.
- c) Eine Varimax-Rotation erhöht die erklärte Varianz.
- d) $KMO > 0,6$ deutet auf eine gute Eignung der Daten für PCA hin.

ENGLISH PART (Questions 6–10)

6. [Open question] (3 Pkt.) What is the main goal of Principal Component Analysis (PCA)? Explain the difference between PCA and Exploratory Factor Analysis (EFA).

7. [Application] (4 Pkt.) A PCA with 20 variables yields the following eigenvalues for the first 6 components:

5.2 | 3.8 | 2.1 | 1.4 | 0.9 | 0.7

- a) How many components would you extract using the Kaiser criterion? (1 pt.)
- b) Calculate the cumulative explained variance for these components in percent. (2 pts.)
- c) What additional decision aid would you use? (1 pt.)

8. [Open question] (3 Pkt.) Why must data be standardized before PCA? What happens if you run PCA on the covariance instead of the correlation matrix?

9. [Application] (4 Pkt.) Interpret the following rotated loading matrix (Varimax, $n = 250$, 10 items):

PC1 PC2 PC3

Item_1	0.82	0.12	0.08
Item_2	0.79	0.05	0.15
Item_3	0.74	-0.08	0.11
Item_4	0.68	0.22	-0.05
Item_5	0.12	0.81	0.03
Item_6	0.08	0.77	0.14
Item_7	-0.05	0.72	0.09
Item_8	0.15	0.11	0.84
Item_9	0.05	0.08	0.79
Item_10	0.18	0.03	0.71

- a) How many components were extracted? Name them substantively. (3 pts.)
- b) Does any item have low loadings on all components (< 0.4)? What would you do? (1 pt.)

10. [MC] (2 Pkt.) Which of the following statements about PCA is correct? Briefly justify.

- a) PCA requires normally distributed variables.
- b) The number of components equals the number of variables.
- c) Varimax rotation increases the total explained variance.
- d) $KMO > 0.6$ indicates good suitability for PCA.

LÖSUNGEN / SOLUTIONS

— Zur Selbstkontrolle / For self-assessment —

1. PCA: Dimensionsreduktion. Fasst viele korrelierte Variablen in wenige unkorrelierte Komponenten zusammen, die maximale Varianz erklären (inkl. Fehlervarianz).

EFA: Nur die gemeinsame Varianz wird modelliert. Ziel: Aufdeckung latenter Konstrukte (theoriegetrieben). PCA = Datenkompression, EFA = Konstruktmessung.

2.a) 4 Komponenten (Eigenwerte > 1 : 5,2 / 3,8 / 2,1 / 1,4).

b) Summe = $5,2 + 3,8 + 2,1 + 1,4 = 12,5$. Relative Varianz: $5,2/20=26\%$, $3,8/20=19\%$, $2,1/20=10,5\%$, $1,4/20=7\%$. Kumuliert: 26 % / 45 % / 55,5 % / 62,5 %.

c) Scree-Plot (Knick in der Kurve) und inhaltliche Interpretierbarkeit der Komponenten.

3. Standardisierung (z-Transformation) ist nötig, weil PCA varianzempfindlich ist. Variablen mit großen Einheiten (z. B. Einkommen in €) würden dominieren.

Kovarianzmatrix-PCA: Variablen mit großer Varianz bekommen höhere Loadings. Korrelationsmatrix-PCA: Alle Variablen sind gleich gewichtet (Standard). Empfehlung: Immer standardisieren, außer alle Variablen haben die gleiche Einheit.

4.a) 3 Komponenten:

PC1: Items 1–4 mit Loadings 0,68–0,82 z. B. 'Führungskompetenz'

PC2: Items 5–7 mit Loadings 0,72–0,81 z. B. 'Teamklima'

PC3: Items 8–10 mit Loadings 0,71–0,84 z. B. 'Arbeitsressourcen'

Keine Kreuzladungen $> 0,3$, klare Struktur.

b) Kein Item mit max. Ladung $< 0,4$. Alle Ladungen $> 0,68$, also gut. Falls doch: Item ausschließen und PCA wiederholen.

5.a) Falsch. PCA ist ein deskriptives Verfahren, keine Normalverteilung nötig (nur für Inferenz).

b) Falsch. Es gibt maximal so viele Komponenten wie Variablen, aber i. d. R. werden nur wenige extrahiert.

c) Falsch. Rotation verteilt die Varianz um, erhöht aber nicht die Gesamtvarianz.

d) Richtig. KMO $> 0,6$ ist akzeptabel, $> 0,8$ ist gut.

6. PCA: dimensionality reduction. Summarizes many correlated variables into few uncorrelated components explaining maximum variance (including error variance).

EFA: Only common variance is modeled. Goal: uncovering latent constructs (theory-driven). PCA = data compression, EFA = construct measurement.

7.a) 4 components (EV > 1 : 5.2 / 3.8 / 2.1 / 1.4).

b) Sum = $5.2 + 3.8 + 2.1 + 1.4 = 12.5$. Relative variance: $5.2/20=26\%$, $3.8/20=19\%$, $2.1/20=10.5\%$, $1.4/20=7\%$. Cumulative: 26% / 45% / 55.5% / 62.5%.

c) Scree plot (elbow in the curve) and interpretability of components.

8. Standardization (z-transform) is necessary because PCA is variance-sensitive. Variables with large units (e.g., income in €) would dominate.

Covariance-based PCA: high-variance variables get higher loadings. Correlation-based PCA: all variables are equally weighted (standard). Recommendation: always standardize, unless all variables share the same unit.

9.a) 3 components:

PC1: Items 1–4 with loadings 0.68–0.82 e.g., 'Leadership'

PC2: Items 5–7 with loadings 0.72–0.81 e.g., 'Team climate'

PC3: Items 8–10 with loadings 0.71–0.84 e.g., 'Work resources'

No cross-loadings > 0.3 , clean structure.

b) No item with max loading < 0.4 . All > 0.68 , good. If there were: exclude item and rerun PCA.

10.a) False. PCA is descriptive; no normality required (only for inference).

b) False. Max = number of variables, but usually only few are retained.

c) False. Rotation redistributes variance but does not increase total.

d) True. KMO > 0.6 is acceptable, > 0.8 is good.