

Diskriminanzanalyse

Methoden-Dossier mit fachspezifischen Beispielen | Standard-Niveau

1. Methodenbeschreibung

Stell dir vor: Ein Kreditinstitut hat Daten von 1.000 Kunden, von denen 50 ihren Kredit nicht zurückgezahlt haben (Ausfall). Kann man anhand von Einkommen, Alter, Bonität vorhersagen, ob ein neuer Kunde ausfallen wird? Das macht die Diskriminanzanalyse.

Die Diskriminanzanalyse ist ein Verfahren zur Klassifikation von Objekten in bekannte Gruppen. Ziel: eine lineare (LDA) oder quadratische (QDA) Diskriminanzfunktion finden, die die Gruppen optimal trennt. Die Funktion ist eine Linearkombination der Prädiktoren: $D = b_1x_1 + b_2x_2 + \dots + b_kx_k$.

LDA (Lineare Diskriminanzanalyse): identische Kovarianzmatrizen über Gruppen hinweg angenommen lineare Trennlinie.
QDA (Quadratische Diskriminanzanalyse): gruppenspezifische Kovarianzmatrizen quadratische Trennlinie. LDA ist robuster bei kleinen Stichproben.

Fisher-Kriterium

Die Diskriminanzfunktion maximiert die Varianz zwischen den Gruppen relativ zur Varianz innerhalb der Gruppen. Der Eigenwert λ gibt das Verhältnis an. Wilks' Lambda testet, ob die Diskriminanzfunktion signifikant trennt.

Klassifikation und Validierung

Die Klassifikationsgüte wird über die Trefferquote (Hit-Rate) oder die Kreuzvalidierung (Leave-One-Out / k-fold) gemessen. Die Confusion-Matrix zeigt: Richtig Positive, Falsch Positive, Richtig Negative, Falsch Negative. Sensitivität und Spezifität ergänzen die Evaluation.

2. Fachbereichsspezifische Beispiele

Sozialwissenschaften

Fragestellung: Welche Faktoren trennen Studienabbrecher von Absolventen? Prädiktoren: Abiturnote, Studienzufriedenheit, finanzielle Situation, soziale Integration. LDA mit 2 Gruppen. $n = 500$. Wilks' Lambda = 0,72 ($p < 0,001$). Trefferquote: 74 %.

Wirtschaftswissenschaften

Fragestellung: Bonitätsprüfung — Unterscheidung zwischen Kreditausfall und Rückzahlung. Prädiktoren: Einkommen, Verschuldungsgrad, Alter, Anzahl Kredite. LDA erreicht 82 % korrekte Klassifikation. Anwendung: Scoring-Modelle im Risikomanagement.

Humanwissenschaften (Medizin)

Fragestellung: Lässt sich anhand von Blutwerten und Vitalparametern zwischen Gesunden und Patienten mit Diabetes Typ 2 unterscheiden? QDA wegen unterschiedlicher Kovarianzen in Gruppen. Sensitivität 89 %, Spezifität 91 %.

Geisteswissenschaften

Fragestellung: Autorschaftsanalyse — Kanonische Diskriminanzanalyse trennt Texte verschiedener Autoren anhand von Stilometrie-Merkmalen (Wortlänge, Satzlänge, Funktionswörter). $n = 100$ Texte, 5 Autoren, 97 % korrekt klassifiziert.

Sportwissenschaften

Fragestellung: Talentsichtung — Diskriminanzanalyse trennt spätere Profi- von Amateur-Fußballern anhand von Leistungstests (Sprint, Sprung, Ausdauer, Koordination). $n = 200$ Jugendliche, LDA, Trefferquote 81 %.

3. Annahmen und Voraussetzungen

- Metrische Prädiktoren (oder binär/ ordinal bei 5+ Stufen)
- Gruppenzugehörigkeit muss bekannt sein (nominal/ binär)
- Multivariate Normalverteilung der Prädiktoren pro Gruppe
- LDA: Homogenität der Kovarianzmatrizen (Box's M-Test, $p > 0,05$)
- QDA: keine Homogenität nötig, braucht aber größere Stichproben
- Keine perfekte Multikollinearität (führt zu instabilen Gewichten)
- Ausreißer erkennen — LDA ist sensitiv auf extreme Werte
- Stichprobengröße: mind. $n > \text{Anzahl Prädiktoren pro Gruppe}$

4. Interpretation und Berichterstattung

Standardbericht:

- Begründung: Warum Diskriminanzanalyse? (Klassifikation vs. erklären)
- Wilks' Lambda + χ^2 -Test: Trennt die Funktion signifikant?
- Eigenwert λ + kanonische Korrelation: Wie stark ist der Zusammenhang?
- Standardisierte Koeffizienten: Welche Prädiktoren tragen wie viel zur Trennung bei?
- Strukturmatrix: Korrelation der Prädiktoren mit der Diskriminanzfunktion
- Confusion Matrix + Trefferquote (original + kreuzvalidiert)
- Sensitivität, Spezifität, positive/negative Prädiktionswerte

Berichtsbeispiel:

"Eine lineare Diskriminanzanalyse mit 5 Prädiktoren trennte die Gruppe der Kreditausfälle ($n = 50$) von Rückzahlern ($n = 450$). Wilks' $\Lambda = 0,68$, $\chi^2(5) = 89,4$, $p < 0,001$. Die kanonische Korrelation betrug 0,57. Stärkster Prädiktor war die Bonitätsstufe ($r = 0,82$). Die kreuzvalidierte Trefferquote lag bei 79,4 %. Sensitivität (Ausfallerkennung) = 72 %, Spezifität = 81 %."

5. Code-Beispiele

R — LDA mit MASS-Paket:

```
library(MASS)
# LDA mit 2 Gruppen
lda_mod <- lda(gruppe ~ einkommen + alter + bonitaet, data = d)
print(lda_mod) # Koeffizienten, Eigenwerte

# Vorhersage + Konfusion
pred <- predict(lda_mod)
table(d$gruppe, pred$class) # Confusion Matrix

# Kreuzvalidierte Trefferquote (LOO)
lda_cv <- lda(gruppe ~ einkommen + alter + bonitaet, data = d, CV = TRUE)
mean(pred$class == d$gruppe)

# Wilks Lambda manuell
library(candisc)
candisc(lda_mod)

# QDA (quadratisch)
qda_mod <- qda(gruppe ~ ., data = d)
```

Python — LDA mit scikit-learn:

```
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis, QuadraticDiscriminantAnalysis
from sklearn.model_selection import cross_val_score
from sklearn.metrics import confusion_matrix, classification_report
import pandas as pd

# LDA
lda = LinearDiscriminantAnalysis()
lda.fit(X, y)
print(lda.coef_) # DiskriminanzKoeffizienten
print(lda.explained_variance_ratio_) # Eigenwerte relativ

# Vorhersage
y_pred = lda.predict(X)
print(confusion_matrix(y, y_pred))
print(classification_report(y, y_pred))

# Kreuzvalidierung
scores = cross_val_score(lda, X, y, cv=10)
print(f"CV-Trefferquote: {scores.mean():.2f} (+/- {scores.std():.2f})")

# QDA
qda = QuadraticDiscriminantAnalysis()
qda.fit(X, y)
```

SPSS — Diskriminanzanalyse:

```
* Diskriminanzanalyse
DISCRIMINANT
/GROUPS=gruppe(0 1)
/VARIABLES=einkommen alter bonitaet
/ANALYSIS ALL
/PRIORS EQUAL
/STATISTICS=MEAN STDDEV UNIVAR BOXM COEFF RAW CORR TABLE
/CLASSIFY=NONMISSING POOLED
/PLOT=COMBINED MAP.

* Ausgabe: Gruppenmittelwerte, Box's M, Wilks' Lambda,
* Eigenwerte, kanonische Korrelation, standardisierte Koeffizienten,
* Strukturmatrix, Klassifikationsergebnisse (original + kreuzvalidiert)
```

6. Erweiterung

Multinomiale / Kanonische Diskriminanzanalyse (CANDISC)

Bei 3+ Gruppen werden mehrere Diskriminanzfunktionen extrahiert (max. $k-1$). Die erste Funktion trennt optimal, die zweite trennt die Restvarianz. Visualisierung: Diskriminanz-Scores als Scatterplot, oft überlappende Gruppenellipsen.

Regularisierte Diskriminanzanalyse (RDA)

Hybrid aus LDA und QDA: ein Parameter λ regularisiert die Kovarianzmatrix. Nützlich bei vielen Prädiktoren ($p > n$), z. B. in der Mikroarray-Analyse.

Logistische Regression als Alternative

Logistische Regression ist flexibler: keine Normalverteilungsannahme, direkte Wahrscheinlichkeiten, einfachere Interpretation (OR). Diskriminanzanalyse ist überlegen bei multivariat normalen Prädiktoren und kleinen Stichproben.

7. Übungsaufgaben

Aufgabe 1: Führe eine LDA mit dem iris-Datensatz durch (Spezies als Gruppe, 4 Prädiktoren). Wie viele Diskriminanzfunktionen gibt es? Wie hoch ist die Trefferquote? Welche Prädiktoren trennen am besten?

Aufgabe 2: Eine Bank hat $n = 200$ Kunden (davon 30 ausgefallen). Prädiktoren: Einkommen (k€), ALTER (Jahre), SCHUFA (0-100). Die LDA zeigt Wilks' $\Lambda = 0,52$, $p < 0,001$. Berechne die kanonische Korrelation. Interpretiere.

Aufgabe 3: Wann verwendest du QDA statt LDA? Wann logistische Regression statt Diskriminanzanalyse? Erstelle eine Entscheidungsmatrix.