

Stichprobenverfahren und Repräsentativität

Wissenschaftstheoretische und methodische Grundlagen

1. Grundgesamtheit vs. Stichprobe

Stell dir vor, du willst wissen, was die Deutschen von einer neuen Wahlrechtsreform halten. 84 Millionen Menschen zu befragen ist unmöglich – zu teuer, zu langsam. Also fragst du 1000 Leute und hoffst, dass die Antworten repräsentativ für alle sind. Aber worauf kommt es an, damit das klappt?

Grundgesamtheit (Population): Alle Individuen, über die du eine Aussage treffen willst.

Stichprobe: Die Teilmenge, die du tatsächlich untersuchst.

Repräsentativität: Die Stichprobe bildet die Population in den relevanten Merkmalen proportional ab. Klingt einfach, ist in der Praxis die größte Herausforderung.

Stichprobenfehler ist die zufällige Abweichung, Bias die systematische – und die ist gefährlicher, weil sie sich nicht durch eine größere Stichprobe verringert.

2. Wahrscheinlichkeitsauswahl (Probability Sampling)

Einfache Zufallsstichprobe: Jedes Element hat gleiche und bekannte Auswahlwahrscheinlichkeit. Goldstandard.

Geschichtete Zufallsstichprobe (Stratified Sampling): Population in Schichten (z.B. Bundesländer) geteilt, pro Schicht Zufallsauswahl. Reduziert Stichprobenfehler, sichert Teilgruppen.

Klumpenstichprobe (Cluster Sampling): Zufallsauswahl von Gruppen (Klassen, Schulen, Gemeinden), dann alle in der Gruppe. Effizienter, aber höherer Stichprobenfehler. Design-Effekt beachten.

Mehrstufige Auswahl (Multi-Stage Sampling): Kombiniert Klumpen und Zufall (z.B. Schule -> Klasse -> Schüler). Typisch in PISA.

3. Nicht-Wahrscheinlichkeitsauswahl (Non-Probability Sampling)

Willkürliche Auswahl (Convenience Sampling): Was gerade verfügbar ist. Studierende, Facebook-Umfragen. Größtes Bias-Risiko.

Quotenauswahl (Quota Sampling): Geschlecht, Alter nach Quoten der Population. Keine Zufallsauswahl innerhalb der Quoten. Häufig in Marktforschung.

Schneeballverfahren (Snowball Sampling): Befragte verweisen auf weitere. Für schwer erreichbare Gruppen (Drogengebraucher, Eliten).

Gezielte Auswahl (Purposive Sampling): Experten werden bewusst ausgewählt. Typisch für qualitative Forschung.

4. Stichprobengröße und Design-Effekt

Notwendiger Stichprobenumfang: Haengt ab von (1) gewünschter Genauigkeit, (2) Heterogenität der Population, (3) Design, (4) geplanter Analyse (Poweranalyse!).

Design-Effekt (deff): Verhältnis der Varianz des Schätzers unter komplexem Design zur Varianz unter einfacher Zufallsstichprobe. Klumpung erhöht deff.

Effektive Stichprobengröße: $n_{\text{eff}} = n / \text{deff}$. 1000 Befragte bei $\text{deff}=2$ entsprechen nur 500 einfachen Zufallsbeobachtungen.

5. Gewichtung

Design-Gewichtung: Korrigiert unterschiedliche Auswahlwahrscheinlichkeiten (z.B. Oversampling von Minderheiten).

Nachgewichtung (Post-Stratification): Anpassung an bekannte Populationsverteilungen (Alter, Geschlecht, Region).
Rakes/Iterative proportional fitting.

Vorsicht: Übergewichtung einzelner Fälle erhöht Stichprobenfehler.

6- Nonresponse und Selektion

Unit-Nonresponse: Ganze Person nimmt nicht teil (verweigert, nicht erreichbar).

Item-Nonresponse: Fehlende Werte bei einzelnen Fragen.

Selektionsbias: Teilnehmer unterscheiden sich systematisch von Nicht-Teilnehmern (gesündere, gebildete Menschen nehmen häufiger an Gesundheitsstudien teil).

Massnahmen: Incentives, mehrfache Kontaktversuche, kurze Frageboegen, Gewichtung, Nonresponse-Analyse.