

Explorative Datenanalyse (EDA)

Wissenschaftstheoretische und methodische Grundlagen

1. Was ist EDA?

Bevor du komplizierte Modelle baust und Signifikanztests jagst, schau dir erstmal deine Daten an. Klingt banal, wird aber oft übersprungen. Die Explorative Datenanalyse (EDA, John Tukey 1977) ist wie der erste Blick in einen Schuhkarton voller Daten: Was ist drin? Gibt es Überraschungen? Sind die Daten überhaupt brauchbar?

Tukeys Philosophie: 'It is important to understand what you CAN DO before you learn what you SUPPOSED TO DO.' EDA priorisiert Grafiken über formale Tests.

Vier Ziele: (1) Daten verstehen, (2) Muster erkennen, (3) Anomalien entdecken, (4) Annahmen für spätere Tests prüfen.

Achtung: EDA erzeugt Hypothesen, sie testet sie nicht. Das machst du später mit neuen, unabhängigen Daten.

2. Lage- und Streuungsmasse

Mittelwert (Mean): arithmetisches Mittel. Empfindlich gegen Ausreißer.

Median: 50%-Perzentil. Robuster gegen Ausreißer.

Modus: häufigster Wert. Einziges Lagemass für Nominalskalen.

Standardabweichung (SD): mittlere Abweichung vom Mittelwert. Quadrierte Einheit.

Interquartilsabstand (IQR): $Q3 - Q1$. Robuster Streuungsindikator.

MAD: Median Absolute Deviation. Noch robuster als SD und IQR.

3. Grafische Verfahren

Histogramm: Verteilung einer Variable. Balkenbreite (bin width) beeinflusst Interpretation. Faustregel: Sturges-Regel oder Freedman-Diaconis.

Boxplot (Box-Whisker-Plot): Median, IQR (Box), $1.5 \cdot \text{IQR}$ (Whisker), Ausreißer (Punkte). Gruppenvergleich nebeneinander.

Violin Plot: Boxplot + Kerndichteschätzung. Zeigt mehr Details (Bimodalität).

Scatterplot: Zusammenhang zweier metrischer Variablen. Überlagerung vermeiden (Transparenz, binning).

Q-Q-Plot: Quantile der Daten gegen Quantile einer theoretischen Verteilung (Normalverteilung). Weicht die Punktwolke von der Diagonalen ab?

Heatmap / Korrelationsmatrix: Visuelle Darstellung aller paarweisen Korrelationen.

Parallel Coordinates: Multivariate Darstellung (alle Variablen als parallele Achsen, jede Beobachtung als Linie).

4. Ausreißer und einflussreiche Punkte

Ausreißer (Outlier): Wert weit entfernt vom Zentrum der Verteilung. Erkennung: $> 3 \cdot \text{IQR}$ vom Median, oder $|z| > 3$.

Einflussreicher Punkt (Influential Case): Einzelfall, der das Modell stark beeinflusst (z.B. Regressionskoeffizient). Erkennung: Cook's Distance, DFBETAS, DFFITS.

Umgang: Nicht automatisch löschen! Ist es ein Messfehler? Eine legitime Variation? Ein neues Phänomen?

Robuste Verfahren: Median statt Mittelwert, Rangkorrelation statt Pearson, robuste Regression (Huber, M-Schätzer).

5. Fehlende Werte erkennen und verstehen

Übersicht: Wie viele fehlen pro Variable? Pro Fall? Gemeinsame Muster?

Grafik: Matrix-Plot der fehlenden Werte (VIM-Paket, missingno in Python).

Mechanismen: MCAR (komplett zufällig), MAR (bedingt zufällig), MNAR (nicht zufällig). Bestimmung nur über Theorie möglich.

Erste-Massnahmen: Nicht einfach löschen (Verzerrung, Informationsverlust). Imputationsplan erstellen (siehe Dossier: Fehlende Werte und Imputation).

6. EDA-Checkliste

- (1) Datensatz-Struktur: Anzahl Zeilen, Spalten, Datentypen.
- (2) Univariate Analyse: Minimum, Maximum, Mittelwert, Median, SD, Schiefe, Kurtosis, Histogramm.
- (3) Fehlende Werte: Anzahl, Muster, MCAR/MAR-Verdacht.
- (4) Bivariate Analyse: Scatterplots, Korrelationsmatrix (Pearson + Spearman).
- (5) Ausreißer: Boxplots, Cook's Distance (wenn Regression geplant).
- (6) Verteilungsannahmen: Normalität (Q-Q-Plot), Homoskedastizität (Residuenplot).
- (7) Dokumentation: Ergebnisse in einem EDA-Report festhalten. Entscheidungen begründen.