

Statistische Datenvisualisierung

Methoden-Dossier | Basic-Niveau

1. Methodenbeschreibung

Gute Datenvisualisierung ist oft wichtiger als die statistische Analyse selbst: Sie macht Muster, Ausreißer und Verteilungen sichtbar, die in Kennziffern unsichtbar bleiben (Anscombes Quartett). Jede Visualisierung sollte informativ, nicht irreführend und für die Zielgruppe verständlich sein.

Verteilungen darstellen

Histogramm: Bins (Klassen) sollten weder zu groß noch zu klein sein. Sturges-Regel: $k = \log_2(n) + 1$. Boxplot: Median, IQR, Whisker ($1,5 \cdot \text{IQR}$), Ausreißer als Punkte. Violinplot: Kombiniert Boxplot mit Kerndichteschätzung. Q-Q-Plot: Test auf Normalverteilung (Punkte auf Diagonale = Normalverteilung).

Zusammenhänge darstellen

Scatterplot: Punktwolke mit ggf. Regressionsgerade (`geom_smooth` in `ggplot`). Bei überlappenden Punkten: Jitter, Transparenz (`alpha`) oder 2D-Histogramm. Scatterplot-Matrix (`pairs`) für mehrere Variablen.

Gruppenvergleiche

Balkendiagramm: Mittelwert $\pm$ Fehlerbalken (95%-KI oder 1 SD). Nicht geeignet für rohe Datenverteilung. Bessere Alternative: Raincloud-Plot (Violin + Stripchart + Boxplot). Gestapelte Balken für kategoriale Daten.

Zeitverläufe

Linienplot: Mittelwert über Zeit $\pm$ CI-Band. Spaghetti-Plot: Einzelverläufe aller Personen (transparent). Slope-Plot: Prä-Post-Veränderung für jede Person.

2. Fachbereichsspezifische Beispiele

Medizin

Forest-Plot fuer Meta-Analyse: Punkt + KI fuer jede Studie. Zusammenfassungs-Diamant unten. Kaplan-Meier-Kurve mit Risikotabelle unter der x-Achse. Bland-Altman-Plot: Differenz gegen Mittelwert zweier Messmethoden.

Psychologie

Raincloud-Plot für Gruppenvergleich (Kontrolle vs. klinische Gruppe). Scatterplot mit Regressionsgerade und 95%-KI-Band für Zusammenhänge. Q-Q-Plot zur Normalverteilungsprüfung.

Wirtschaftswissenschaften

Heatmap der Korrelationsmatrix (corrplot). Wasserfall-Chart für Gewinn-Veränderungen. Zeitreihen mit gleitendem Durchschnitt und Prognoseintervall.

Sportwissenschaften

Spaghetti-Plot für Leistungsentwicklung mehrerer Athleten über Seasons. Bland-Altman für Methodenvergleich (z. B. zwei Sprungkraftmessgeräte).

3. Grundsätze guter Visualisierung

y-Achse bei 0 beginnen (außer bei logarithmierten Daten oder Differenzen)

Kein 3D (verzerrt Proportionen, erschwert Ablesen)

Farben: farbenblindfreundlich (ColorBrewer, viridis), konsistent

Daten-Tinte-Verhältnis maximieren (Tufte) — Chartjunk vermeiden

Beschriftungen: Achsen, Legende, Titel — selbsterklärend

4. Code-Beispiele

R - ggplot2:

```
library(ggplot2)
# Histogramm
ggplot(df, aes(x=wert)) + geom_histogram(bins=30) + theme_minimal()
# Boxplot + Violin
ggplot(df, aes(x=gruppe, y=wert)) + geom_violin() + geom_boxplot(width=0.2)
# Scatterplot + Regression
ggplot(df, aes(x=x, y=y)) + geom_point(alpha=0.5) + geom_smooth(method="lm")
# Raincloud-Plot
library(raincloudplots)
# Forest-Plot
library(forestplot)
# Kaplan-Meier
library(survminer); ggsurvplot(fit)
# Korrelations-Hitmap
library(corrplot); corrplot(cor(df))
```

Python - matplotlib/seaborn:

```
import matplotlib.pyplot as plt
import seaborn as sns
# Histogramm
sns.histplot(data=df, x="wert", bins=30)
# Boxplot + Violin
sns.violinplot(data=df, x="gruppe", y="wert")
sns.boxplot(data=df, x="gruppe", y="wert", width=0.2)
# Scatterplot + Regression
sns.regplot(data=df, x="x", y="y")
# Pairplot
sns.pairplot(df)
# Heatmap
sns.heatmap(df.corr(), annot=True, cmap="RdBu_r")
```

5. Erweiterung

Interaktive Visualisierungen

plotly (R/Python): Zoom, Tooltips, Animation. Für explorative Analysen und Dashboards. shiny (R) / dash (Python) für interaktive Web-Apps.

Spezialplots

Venn-Diagramm (Schnittmengen, auch eulerr), Sankey-Diagramm (Flows), Network-Plot (Netzwerke), Chord-Diagramm (Beziehungen zwischen Gruppen), Geomapping (choropleth).

6. Übungsaufgaben

Aufgabe 1: Du hast 2 Gruppen ($n=50$) mit metrischer AV. a) Welcher Plot-Typ zeigt die Verteilung am besten? b) Erstelle den Plot in R oder Python. c) Welche Information fehlt in einem reinen Balkendiagramm mit Fehlerbalken?

Aufgabe 2: Ein Scatterplot von 500 Punkten zeigt Überlappung. a) Drei Methoden, um Überlappung sichtbar zu machen. b) Ein Kollege verwendet 3D-Balken — warum ist das problematisch?